



TALLER PRÁCTICO

Guía Metodológica de Estudio: Regresión Lineal y Regresión Logística

Machine Learning I (ML1-2026I) | Sesiones del 8 y 10 de
abril de 2026

Julián Zuluaga — Docente

7 de abril de 2026


Guía Metodológica de Estudio: Regresión Lineal y Regresión Logística

Machine Learning I (ML1-2026I) | Universidad Externado de Colombia | Ciencia de Datos — Semestre IV


Profesor: Julián Zuluaga

Sesiones: Miércoles 8 de abril de 2026 y viernes 10 de abril de 2026


Naturaleza del documento: guía metodológica de estudio y apoyo para el trabajo en clase



MAE
RMSE
 R^2



TP	FP
FN	TN



Dos sesiones, dos modelos y una misma idea central: modelar, interpretar y decidir con criterio.

Propósito de esta guía

Esta guía no está pensada como examen ni como lista de ejercicios mecánicos. Su función es orientar la manera en que debes **mirar los datos, leer los gráficos, interpretar las métricas y justificar decisiones de modelado**.

En estas dos sesiones trabajaremos con dos preguntas distintas:

1. **Regresión lineal:** ¿cómo cambia una variable numérica continua cuando cambia otra?

2. Regresión logística: ¿cómo cambia la probabilidad de un evento binario cuando cambian ciertos factores?

La meta no es memorizar fórmulas sueltas. La meta es que puedas responder, con lenguaje claro:

- qué está aprendiendo el modelo,
- qué tan bien se equivoca,
- cuándo un número parece bueno pero engaña,
- y cómo defender una interpretación frente a datos reales.

Cómo usar esta guía

- Léela antes de la clase para llegar con un mapa mental claro.
- Durante la sesión, úsala como checklist de observación.
- Antes de ejecutar una celda o mirar una salida, intenta responder la pregunta conceptual.
- Después de la clase, vuelve a esta guía para consolidar vocabulario e intuiciones.

Sesión 1

Regresión lineal, métricas de error, R^2 y ajustes polinomiales

Sesión 2

Regresión logística, matriz de confusión, umbral, odds, log-odds e interpretabilidad

Datasets de trabajo

Sesión	Dataset	Tarea	Razón pedagógica
Regresión lineal	Auto MPG (UCI)	Predecir <code>mpg</code> a partir de variables del vehículo	Permite gráficos muy limpios, errores interpretables y curvaturas visibles
Regresión logística	Student Performance (UCI)	Predecir si un estudiante aprueba o no	Hace natural hablar de probabilidad, umbral, errores de clasificación y odds ratio

Dataset 1 — Auto MPG

- **Fuente:** UCI Machine Learning Repository
- **Problema:** regresión
- **Target:** `mpg` (millas por galón)
- **Variables especialmente útiles para la sesión:** `horsepower`, `weight`, `acceleration`, `model_year`
- **Observación importante:** `horsepower` tiene algunos valores faltantes y habrá que limpiarlos antes de modelar.

Dataset 2 — Student Performance

- **Fuente:** UCI Machine Learning Repository
- **Problema original:** clasificación/regresión
- **Target propuesto para la sesión:** `aprueba = 1` si `G3 >= 10`, `0` en caso contrario
- **Variables candidatas para el modelo:** `studytime`, `failures`, `absences`, `higher`, `schoolsup`, `goout`
- **Observación importante:** no conviene usar `G1` ni `G2` en el modelo principal, porque contienen demasiada información cercana a la nota final y distorsionan el ejercicio interpretativo.

La pregunta transversal de ambas sesiones

Un modelo no se juzga solo porque “da un número”. Se juzga por la relación entre lo que predice, el error que comete y la interpretación que permite construir.

“ Modelar no es apretar un botón. Modelar es decidir qué pregunta vale la pena responder, con qué variables, bajo qué criterio de error y con qué nivel de interpretabilidad.

Enfoque esperado para ML1

Sesión 1 — Regresión Lineal, Error, R^2 y Ajustes Polinomiales


Pregunta central

¿Cómo cambia el consumo de combustible de un vehículo cuando cambia la potencia de su motor?

La sesión empezará con una relación sencilla y muy visual: **horsepower** contra **mpg**. A partir de ahí construiremos una secuencia que va desde la intuición gráfica hasta la comparación entre modelos con distinta complejidad.

Qué debes ser capaz de entender al terminar

1. Qué significa ajustar una recta sobre una nube de puntos.
2. Qué es un residuo y cómo se interpreta en contexto.
3. Qué diferencia hay entre **MAE**, **MSE** y **RMSE**.
4. Qué significa realmente R^2 .
5. Por qué un ajuste polinomial puede mejorar el modelo o destruir su capacidad de generalización.
6. Por qué “una curva bonita” no es evidencia suficiente.



La ruta de la sesión 1: nube de puntos, recta, residuos, métricas y el salto hacia la complejidad polinomial.

1.1 Antes de modelar: mirar la nube de puntos

La primera obligación no es entrenar. La primera obligación es **mirar**.

Con `horsepower` en el eje X y `mpg` en el eje Y, debes preguntarte:

- ¿La relación parece decreciente o creciente?
- ¿Se ve aproximadamente lineal?
- ¿Hay curvatura?
- ¿Hay puntos extremos?
- ¿La dispersión es parecida en todo el rango o cambia?

Lo que esperamos conceptualmente: a mayor potencia, menor eficiencia de combustible. Eso significa una pendiente negativa. Pero también es razonable esperar que la relación no sea perfectamente lineal: al crecer `horsepower`, el deterioro de `mpg` puede curvarse.

1.2 La recta no “adivina”: compite contra un baseline

Cuando ajustamos una recta, no estamos preguntando solo si “pasa cerca” de los puntos. La comparación correcta es:

- **Modelo ingenuo:** predecir siempre el promedio de `mpg`
- **Modelo lineal:** usar `horsepower` para explicar variación alrededor de ese promedio

Aquí aparece una idea fundamental:

`R2` no mide perfección absoluta. Mide cuánto mejora el modelo respecto a predecir siempre la media.

Si el modelo lineal mejora mucho frente al promedio, `R2` sube. Si apenas mejora, `R2` baja. Si incluso empeora, `R2` puede ser negativo.

1.3 Residuo: el concepto más importante de la sesión

El residuo se define como:

$$\text{residuo} = \text{valor_real} - \text{valor_predicho}$$

No es una formalidad algebraica. Es la unidad básica para entender el error.

Interpretación directa:

- residuo positivo: el valor real quedó por encima de lo que el modelo esperaba

- residuo negativo: el valor real quedó por debajo
- residuo grande en valor absoluto: el modelo falló mucho en ese punto

Lo que debes observar en el gráfico de residuos:

- si están centrados alrededor de 0,
- si forman patrón,
- si se abre un “abanico”,
- si ciertos rangos de X concentran errores más grandes.

Cuando los residuos muestran estructura, eso suele indicar que la recta no está capturando bien la forma de la relación.

1.4 Tres métricas, tres énfasis distintos

En esta sesión queremos que las métricas de error se vuelvan intuitivas, no decorativas.

MAE

MAE es el error absoluto promedio.

Sirve para responder:

“En promedio, ¿cuánto se equivoca el modelo en unidades naturales del problema?”

En Auto MPG, eso se puede leer como:

“En promedio, el modelo falla por X millas por galón.”

MSE

MSE es el promedio de los errores al cuadrado.

Su utilidad no es interpretativa sino analítica:

- penaliza más los errores grandes,
- hace muy visibles los outliers,
- es el criterio clásico que minimiza la regresión lineal.

El problema es que queda en unidades cuadradas, por eso no se interpreta con naturalidad frente a estudiantes que apenas están construyendo intuición.

RMSE

$$\text{RMSE} = \sqrt{\text{MSE}}$$

Suele ser la métrica más cómoda para discusión en clase porque:

- mantiene la sensibilidad a errores grandes,
- pero vuelve a las unidades originales del target.

Regla pedagógica útil:

- usa **MAE** para hablar de error promedio “típico”,
- usa **RMSE** para mostrar cuánto castigan los errores grandes.

1.5 Qué debe provocar discusión en clase

No basta con calcular métricas. La discusión correcta es:

- Si **RMSE** es bastante mayor que **MAE**, ¿qué sugiere eso sobre errores grandes?
- Si el ajuste visual parece bueno pero **R²** no es tan alto, ¿qué significa?
- Si el **R²** sube muy poco al agregar flexibilidad, ¿vale la pena complicar el modelo?
- Si el modelo se ve bien en train, ¿qué falta todavía para confiar?

1.6 Qué significa realmente R²

R² es muy útil, pero se malinterpreta con demasiada facilidad.

Interpretación correcta:

“El modelo explica cierta proporción de la variación del target respecto a un baseline que predice siempre la media.”

Interpretaciones incorrectas que debemos evitar:

- “R² alto prueba causalidad”
- “R² alto significa que el modelo sirve para cualquier contexto”
- “R² bajo implica que no hay relación”
- “R² siempre basta para decidir entre modelos”

En la sesión queremos que el estudiante entienda que **R²** es una **medida relativa de ajuste**, no una garantía epistemológica.

1.7 El salto importante: cuando la recta no alcanza

Aquí entra el ajuste polinomial.

La idea no es “hacer magia” con una curva. La idea es permitir que el modelo capture relaciones que no son estrictamente lineales.

Por ejemplo, si usamos:

- grado 1: tenemos una recta,
- grado 2: permitimos curvatura simple,
- grado 3 o 5: permitimos formas más flexibles.

Pero más flexibilidad no significa automáticamente mejor modelo.

1.8 La pregunta clave de la segunda mitad

¿Cuándo una mejora del ajuste es una mejora real y cuándo es solo sobreajuste?

La respuesta debe salir de tres cosas al mismo tiempo:

1. **Gráfico del ajuste**
2. **Error en train**
3. **Error en test**

Si el error en train baja siempre, pero el error en test empieza a subir, el modelo está empezando a perseguir ruido.

1.9 Qué debe mirar el estudiante al comparar grados

Cuando compares grado 1, 2, 3 o 5, no te fijes solo en cuál curva “pasa más cerca”.

Debes mirar:

- si la curva captura la forma general,
- si introduce oscilaciones raras,
- si cambia mucho cuando cambia el conjunto de entrenamiento,
- si el error de test mejora o empeora.

Lenguaje esperado en la interpretación:

- “grado 1 subajusta porque no captura curvatura”
- “grado 2 o 3 parece recoger la tendencia principal sin volverse errático”
- “grado 5 empieza a perseguir variaciones locales que no generalizan”

1.10 Lo que queremos que quede instalado

Al terminar esta sesión, la intuición correcta es:

- un buen modelo no es el que minimiza error en train,
- una métrica aislada nunca reemplaza el gráfico,
- R^2 sirve, pero no manda solo,
- la complejidad debe justificarse por generalización, no por estética.

1.11 Preguntas guía para estudiar antes o después de la sesión

1. ¿Qué significa que un residuo sea positivo?
2. ¿Por qué $RMSE$ suele ser más sensible que MAE a errores extremos?
3. ¿Contra qué baseline compara R^2 ?
4. ¿Puede un modelo tener un gráfico “bonito” y generalizar mal?
5. ¿Qué evidencia concreta de overfitting buscarías al comparar grados polinomiales?
6. ¿Por qué el mejor modelo no siempre es el de mayor complejidad?

1.12 Pistas metodológicas para cuando estés resolviendo en clase

- Antes de correr un modelo, describe la forma esperada de la relación.
- Antes de leer una métrica, di qué esperarías ver en el gráfico.
- Si dos modelos tienen resultados parecidos, prefiere el más simple salvo evidencia clara en contrario.
- Si no puedes explicar un resultado en palabras, todavía no lo entendiste.

“ En regresión lineal, el objetivo no es solo dibujar una recta. El objetivo es entender qué parte de la variación capturamos, cómo se distribuye el error y cuándo la complejidad deja de ayudar.

Idea central de la sesión 1

Sesión 2 — Regresión Logística, Umbral, Matriz de Confusión y Odds


Pregunta central

¿Cómo cambia la probabilidad de que un estudiante apruebe cuando cambian variables como tiempo de estudio, ausencias o fracasos previos?

En esta sesión ya no predecimos una cantidad continua. Ahora modelamos la probabilidad de un evento binario: aprobar o no aprobar.

Qué debes ser capaz de entender al terminar

1. Por qué la salida de la logística es una probabilidad y no una recta sin límites.
2. Cómo pasar de probabilidad a decisión mediante un umbral.
3. Cómo leer una matriz de confusión.
4. Qué significan **odds**, **log-odds** y **odds ratio**.
5. Cómo interpretar el signo y el tamaño de un coeficiente logístico.
6. Por qué mover el umbral cambia el tipo de error que comete el modelo.



La ruta de la sesión 2: puntaje lineal, sigmoide, probabilidad, umbral, matriz de confusión e interpretación con odds.

2.1 La primera idea: el modelo no predice etiquetas, predice probabilidades

Una regresión logística no empieza diciendo “aprueba” o “no aprueba”. Empieza calculando un puntaje lineal:

$$z = \text{beta_0} + \text{beta_1} * x_1 + \text{beta_2} * x_2 + \dots$$

Luego transforma ese puntaje con la sigmoide para obtener un valor entre 0 y 1:

$$P(\text{aprueba}) = 1 / (1 + \exp(-z))$$

Lo importante aquí no es memorizar la fórmula, sino entender su lógica:

- el puntaje lineal puede ser cualquier número real,
- la sigmoide lo convierte en una probabilidad interpretable,
- la decisión final depende de un umbral.

2.2 El modelo tiene dos capas conceptuales

1. **Capa de puntuación:** combina variables de manera lineal
2. **Capa de decisión:** convierte esa puntuación en probabilidad y luego en clase

Esto es importante porque muchas confusiones vienen de mezclar tres objetos distintos:

- el puntaje z ,
- la probabilidad,
- la clase final.

2.3 Qué son las odds

Las odds no son lo mismo que la probabilidad.

Si una probabilidad es p , entonces:

$$\text{odds} = p / (1 - p)$$

Ejemplos intuitivos:

Probabilidad	Odds
0.50	1.00
0.80	4.00
0.20	0.25
0.90	9.00

Interpretación:

- odds = 1 significa equilibrio
- odds > 1 favorece el evento
- odds < 1 desfavorece el evento

Lo que debes cuidar mentalmente: una odds de 4 no significa probabilidad 4. Significa que el evento es cuatro veces más probable que su complemento en términos de razón.

2.4 Qué son los log-odds

La regresión logística modela linealmente los **log-odds**, no la probabilidad directa.

$$\text{log-odds} = \log(p / (1 - p))$$

¿Por qué esto es útil?

- porque los log-odds sí pueden moverse libremente en toda la recta real,
- y eso permite usar una combinación lineal de variables.

Conceptualmente:

- si **z** aumenta, la probabilidad aumenta,
- si **z** disminuye, la probabilidad baja,
- pero el efecto sobre la probabilidad no es constante en todo el rango.

2.5 La interpretación más importante: exp(beta)

En logística, el coeficiente **beta** no se interpreta directamente en unidades de probabilidad.

La cantidad útil es:

$$\exp(\text{beta})$$

Eso se interpreta como **odds ratio**.

Ejemplo conceptual:

si para **studytime** tenemos **beta = 0.40**, entonces:

$$\exp(0.40) \approx 1.49$$

Interpretación correcta:

Por cada unidad adicional de tiempo de estudio, las odds de aprobar se multiplican por 1.49, manteniendo las demás variables constantes.

Interpretación incorrecta:

“la probabilidad sube 49%”

Ese salto no es válido en general. La relación entre odds y probabilidad no es lineal.

2.6 Qué variables conviene usar en esta sesión

Para favorecer interpretación, el modelo debe ser pequeño y defendible.

Una combinación razonable es:

- `studytime`
- `failures`
- `absences`
- `higher` codificada como 0/1

Estas variables permiten preguntas interpretables:

- ¿más estudio aumenta la probabilidad de aprobar?
- ¿tener fracasos previos la reduce?
- ¿más ausencias empeoran el pronóstico?
- ¿querer educación superior se asocia con mejor resultado?

2.7 El umbral: el paso donde la probabilidad se vuelve decisión

Supón que el modelo predice:

- Estudiante A: 0.82
- Estudiante B: 0.63
- Estudiante C: 0.48
- Estudiante D: 0.29

Con umbral 0.5:

- A y B se clasifican como “aprueba”
- C y D como “no aprueba”

Con umbral 0.3:

- A, B y C pasan a “aprueba”
- D sigue como “no aprueba”

Esto muestra la idea central:

El umbral no cambia la probabilidad predicha. Cambia la decisión que tomamos a partir de ella.

2.8 La matriz de confusión como mapa de errores

Una vez definimos el umbral, aparecen cuatro resultados:

- **TP** : predijo aprueba y realmente aprobó
- **FP** : predijo aprueba y realmente no aprobó
- **FN** : predijo no aprueba y realmente sí aprobó
- **TN** : predijo no aprueba y realmente no aprobó

Lo importante en clase no es solo nombrarlos, sino preguntar:

- ¿qué error me preocupa más en este contexto?
- ¿prefiero dejar pasar estudiantes que sí podían aprobar?
- ¿o prefiero marcar como “riesgo” a estudiantes que luego sí aprobaban?

2.9 Qué cambia al mover el umbral

Cuando bajas el umbral:

- aumentan los positivos predichos,
- sube el recall de la clase positiva,
- pero suelen aumentar los falsos positivos.

Cuando subes el umbral:

- el modelo se vuelve más exigente,
- cae el número de positivos predichos,
- suele mejorar la precisión,
- pero pueden crecer los falsos negativos.

La lección es que el umbral no es un detalle técnico. Es una decisión sobre el tipo de error que estás dispuesto a aceptar.

2.10 Qué queremos que pase en la discusión

No queremos que el estudiante diga solo:

“el modelo tuvo accuracy de X”

Queremos que diga algo como:

“Con umbral 0.5 el modelo acierta razonablemente, pero deja escapar varios casos positivos. Si bajo el umbral a 0.4 recupero más positivos, aunque a costa de más falsas alarmas.”

Ese es el tipo de lenguaje que muestra comprensión real.

2.11 Qué observar en los gráficos

En la sesión debes mirar cuatro representaciones distintas:

1. Curva sigmoide

Para entender que la salida está acotada entre 0 y 1.

2. Distribución de probabilidades predichas

Para ver si el modelo separa bien a quienes aprueban y quienes no.

3. Matriz de confusión

Para aterrizar el tipo de error concreto.

4. Tabla de coeficientes y odds ratio

Para traducir el modelo a lenguaje interpretativo.

2.12 Qué errores conceptuales queremos evitar

- creer que un coeficiente positivo significa causalidad,
- confundir odds con probabilidad,
- afirmar que `exp(beta)` aumenta la probabilidad en ese mismo factor,
- elegir el umbral por costumbre y no por criterio,
- quedarse solo con accuracy.

2.13 Lo que debe quedar instalado

Al terminar esta sesión, la intuición correcta es:

- la logística estima probabilidades,

- la clase final depende del umbral,
- la matriz de confusión traduce probabilidades en consecuencias,
- $\exp(\text{beta})$ se interpreta sobre odds,
- interpretar bien importa tanto como clasificar bien.

2.14 Preguntas guía para estudiar antes o después de la sesión

1. ¿Por qué una regresión lineal no es adecuada para predecir probabilidades?
2. ¿Cuál es la diferencia entre probabilidad y odds?
3. ¿Qué modela linealmente la regresión logística: la probabilidad o los log-odds?
4. ¿Qué significa que $\exp(\text{beta}) = 1.8$ para una variable?
5. ¿Qué ocurre con los falsos positivos y falsos negativos cuando se baja el umbral?
6. ¿Por qué accuracy sola puede ocultar un modelo mal calibrado para la decisión?

2.15 Pistas metodológicas para cuando estés resolviendo en clase

- Antes de ver la matriz, predice qué errores esperas encontrar.
- Cuando leas un coeficiente, piensa primero en dirección y luego en magnitud.
- Traduce siempre $\exp(\text{beta})$ a una frase con “las odds se multiplican por...”.
- Si cambias el umbral, explica qué tipo de error decidiste tolerar más.

“ La regresión logística no solo clasifica. Organiza una cadena completa de interpretación: puntaje, probabilidad, umbral, error y decisión.

Idea central de la sesión 2

Cierre — Qué se espera que puedas hacer después de estas dos sesiones

Al finalizar este bloque deberías poder:

1. Elegir una visualización inicial apropiada para un problema de regresión o clasificación.
2. Explicar por qué una métrica determinada sí o no responde a la pregunta del problema.
3. Justificar verbalmente qué significa un ajuste lineal, un residuo, un R^2 o un RMSE.
4. Explicar por qué un modelo polinomial puede mejorar o empeorar la generalización.
5. Leer una matriz de confusión sin depender de una definición memorizada.

6. Interpretar coeficientes logísticos usando odds ratio.
7. Defender un umbral de decisión con criterio, no por costumbre.

Recordatorio final

En clase no buscamos que “adivines el output”. Buscamos que puedas anticiparlo conceptualmente, observarlo críticamente y explicarlo con precisión.

Si antes de correr una celda eres capaz de decir:

- qué esperas ver,
- por qué lo esperas,
- y qué cambiaría tu conclusión,

entonces ya estás pensando como alguien que modela con criterio.